




Normal Dağılım




Y Ekseninde Kaymalar Olduğunda




Y Ekseninde Kaymalar Olduğunda




X Ekseninde Kaymalar Olduğunda



X Ekseninde Kaymalar Olduğunda




Mevcut veri referans verisinden az olunca



Referans Verisi : 100000 adet

Güncel Veri: 1000adet


Mevcut veri referans verisinden az olunca



Referans Verisi : 100000 adet


Güncel Veri: 100 adet

Referans verisi mevcut veriden az olunca



Referans Verisi : 1000 adet
Güncel Veri: 100000 adet

Referans verisi mevcut veriden az olunca



Referans Verisi : 100 adet
Güncel Veri: 100000 adet

Sonuçlar

Wasserstein algoritması

- Farkları tespit etmekte daha iyi sonuç üretiyor.
- X ve Y ekseninde kaymaları tespit edebiliyor.
- Bir dağılımı diğer dağılıma çevirirken gereken işi hesaplayıp sonuç üretiyor.
- Veri dağılımı şeklinin önemli olduğu senaryolarda öne çıkıyor.(görüntü işleme)

Jensen-Shannon algoritması

- Olasılık bazlı hesaplayıp simetrik benzerliğe göre çıktı üretiyor.
- Eksen kaymaları sonucu etkilemiyor.
- Data overlap etmediği durumlarda ürettiği sonuç işlevsel olmuyor.
- NLP alanlarında tercih ediliyor.

Following examples by Arjovsky et al (2017) and Kolouri et al (2018), [Kolouri et al \(2019\)](#) shows a simple example in the supplementary material comparing the Jensen-Shannon divergence with the Wasserstein distance.

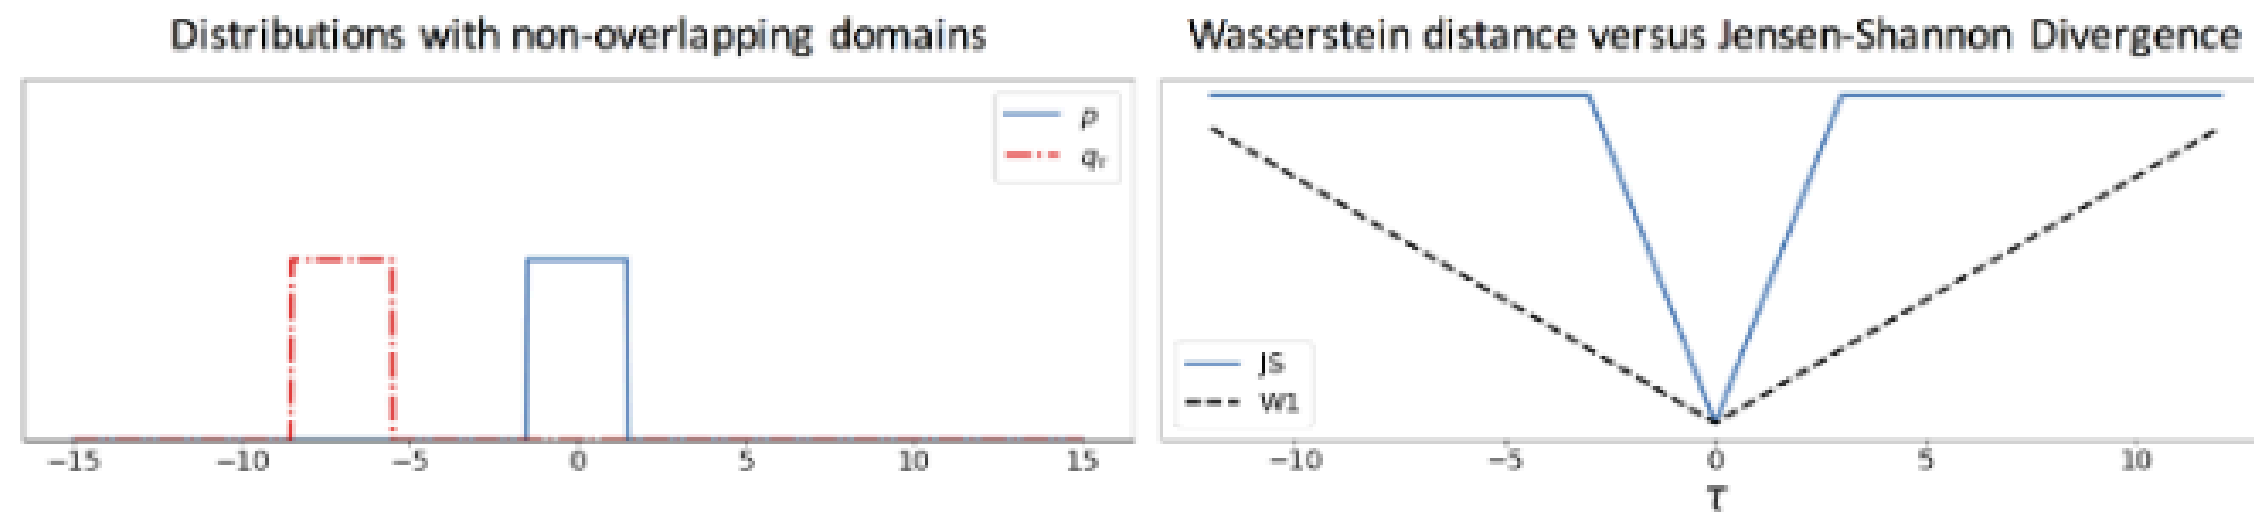


Figure 6: These plots show $W_1(p, q_\tau)$ and $JS(p, q_\tau)$ where p is a uniform distribution around zero and $q_\tau(x) = p(x - \tau)$. It is clear that JS divergence does not provide a usable gradient when distributions are supported on non-overlapping domains.

As can be seen the JS divergence fails to provide a useful gradient when the distributions are supported on non-overlapping domains.